

R :

TD1 :

getwd()

#Création et suppression des fenêtres graphiques

x11()

dev.off()

#Création des diagrammes et des différentes fonctionnalités
(variables qualitatives)

vec=c(12,10,7,13,26,16,4,12)

pie(vec)

names(vec)=LETTERS[1:8]

vec

barplot(vec, col=rainbow(8))

par(mfrow=c(2,2))

par(mfcol=c(2,1))

barplot(c(1,1,1,2,2,3,1,1,2,3))

lines(c(1,1,1,2,2,3,1,1,2,3), col="red")

tablec=table(c(1,1,1,2,2,3,1,1,2,3))

barplot(tablec, col=c("red", "blue", "green"))

hist(c(1,1,1,2,2,3,1,1,2,3))

colors()

mosaicplot(vec)

#Variables quantitative

x=rnorm(50,m=0,sd=1);x

boxplot(x)

hist(x, nclass=10)

hist(x, breaks=c(-3,0,3))

```

hist(x, breaks=seq(-3,3, by=0.5), xlim=c(-3,3))
stripchart(x, xlim=c(-3,3))
points(x,rep(0,50),col="red", pch=12)

x=seq(-10,10,l=500)
plot(x,sin(x), type="l")
plot(x,cos(x), type="l", main="Courbe de la fontion Sinus",
ylab="sin(x)", xlab="x")
lines(x,sin(x),col="red")
abline(v=0, col="blue", lwd=5,lty=3)
text(-5,-0.5,"texte",font=3)
dev.copy2pdf(file="courbes_sin_cos.pdf")
write.table(x,file="simulationx.csv")
save(x,file="simulationr.Rdata")

```

TD2 :

```

getwd()
data=read.table(file="Classe.data.txt", header=T)
head(data)
str(data)
attach(data)
x11()
departement
ls()
#Departement
eff_dep = table(departement);eff_dep
freq_dep = (1/sum(eff_dep))*eff_dep;freq_dep
barplot(freq_dep)
pie(table(departement))
#Sexe
eff_sexe = table(sexe);eff_sexe

```

```
freq_sexe = (1/sum(eff_sexe))*eff_sexe;freq_sexe
barplot(table(sexe))
pie(table(sexe))
#Serie
table(serie)
barplot(table(serie))
pie(table(serie))
```

TD3 :

#Exo1 :

#Q1

```
donnees=rnorm(n=150,mean=0,sd=1)
```

#Q2

```
hist(donnees,br=breakpoints,freq=FALSE,main="Histogramme des données",xlab="Valeurs des données",ylab="Fréquence")
points(x=donnees,y=rep(0,times=150),col="red",pch=4)
```

#Q3

#L'histogramme correspond

#Q4

```
range(donnees)
breakpoints=(seq(-4,4,by=0.5))
```

```
xlines=seq(-4,4,by=0.25)
```

```
lines(x=xlines,y=dnorm(x=xlines,m=0,sd=1),col="blue")
```

#Exo2 :

#Q1

```
salaires=c(12000:14000,14000:16000,16000:21000,21000:
26000,26000:36000,36000:50000)
effectif=c(50,190,210,40,4,2)
data.frame(salaires,effectif)
```

```
#Q2
freq(salaires)
freq(effectif)
```

```
#Q3
```

```
#Exo3 :
robinet=read.table(file="robinet.txt")
View(robinet)
```

```
#Q1
attach(robinet)
consommation[2]
summary(consommation)
quantile(consommation)
mean(consommation)
var(consommation)
```

```
#Q2
x11()
boxplot(consommation)
par(mfcol=c(1,1))
plot(ecdf(consommation),main="Courbe des fréquences
cumulées")
```

```
#Q3
```

```
hist(consommation, freq=TRUE,ylab="Effectifs")
hist(consommation, freq=FALSE,ylab="Densité")
hist(consommation,
freq=FALSE,ylab="Densité",nclass=100,ylim=c(0,0.003))
br1=c(0,50,100,150,200,350,550,800,1100,1450,3000)
hist(consommation,
freq=FALSE,ylab="Densité",br=br1,ylim=c(0,0.003))
```

```
#Q4
```

```
x=seq(0,3000,by=100)
moyenne1=mean(consommation);moyenne1
y=(1/moyenne1)*exp(-(1/moyenne1)*x)
y=dexp(x,rate=1/moyenne1)
lines(x,y,col="red")
help(dexp)
```

```
#Comment faire un tableau d'effectifs avec répartition par
classe
table(consommation)
table(cut.consommation=cut(consommation,breaks=seq(0,3
000,by=200)))
```

```
#Exo4 :
```

```
#Si l'on avait affaire à une série de données, les effectifs
seraient uniformément répartis dans chaque classe : on
re crée une série ARTIFICIELLE
```

```
#Q1
```

```
atterissages=c(runif(112,60,120),runif(176,120,140),runif(4
61,140,180),runif(157,180,200),runif(94,200,260))
br2=c(60,120,140,180,200,260)
hist(atterissages,breaks=br2)
```

```

#Q2
plot(ecdf(atterissages))
effectifs.atterissages=c(0,112,176,461,157,94)
cumfreq.atterissages=cumsum(effectifs.atterissages)/sum(e
fectifs.atterissages)
par(mfrow=c(1,2))
plot(cumfreq.atterissages,br2,type="l")
plot(ecdf(atterissages))
#Graphiquement médiane et quartile
lines(c(60,260),c(0.25,0.25),col="green") #Q1
lines(c(60,260),c(0.5,0.5),col="red") #Q2 et médiane
lines(c(60,260),c(0.75,0.75),col="blue")#Q3
#Par le calcul
sum(effectifs.atterissages)
#on localise la classe
500-176-112
500-176-112-461
#On constate que la médiane est la 212ème valeur de la
classe [140;180[
mediane.atterissages=(212/461)*(180-
140)+140;mediane.atterissages

#Q3
moyenne.atterissages=(1/sum(effectifs.atterissages)*sum(e
fectifs.atterissages))
sd.atterissages

#Q4
hist(atterissages,breaks=br2)

```

```
#Ca ressemble à une loi normale  
x=seq(0,300,by=10)
```

```
TD4 :  
getwd()
```

```
#Exo0  
#Q1  
ventes=c(25,30,35,45,65);ventes #variable réponse  
depenses=c(5,6,9,12,18);depenses #variable explicative  
tableau=data.frame(depenses,ventes);tableau
```

```
#Q2  
x11()  
dev.off()  
plot(tableau, main="Nuage de points des ventes en fonction  
des dépenses") # ou plot(ventes~depenses,data=tableau)  
#On observe une dépendance qui semble linéaire  
cor(tableau) # Corrélaton  $\sum(x - \text{moy}(x))(y - \text{moy}(y))$ 
```

```
#Exo1  
#Q1  
age=c(5,4,6,5,5,5,6,6,7,7)  
km=c(92,64,124,97,79,76,93,63,111,143)  
prix=c(7.8,9.5,6.4,7.5,8.1,9,6.1,9.7,6.4,4.4)  
agePrix=data.frame(age,prix)  
kmPrix=data.frame(km,prix)
```

```
#Q2  
x11()  
par(mfrow=c(1,2))
```

```
plot(agePrix, main="Le prix en fonction de l'age")  
plot(kmPrix, main="Le prix en fonction du kilometrage")
```

```
#Q3
```

```
#On observe une dépendance entre le kilometrage et le prix  
qui semble linéaire  
cor(kmPrix)
```

```
#Q3a
```

```
lmExo1=lm(prix~km, data=kmPrix);lmExo1  
abline(lmExo1, col='red')  
summary(lmExo1)  
residuals((lmExo1))  
#R-squared : "Pourcentage des données pouvant être  
expliquées par la relation LINEAIRE proposée : entre 0 et 1
```

```
#Q3b
```

```
prix=ax+b
```

```
#Q3c
```

```
points(mean(kmPrix$km),mean(kmPrix$prix),col='blue')
```

```
#Q3d
```

```
help(predict)  
predict(lmExo1, data.frame(km=150))
```

```
#Exo2
```

```
#Q1a
```

```
rangAnnee=c(0:6) #variable explicative  
montantAchat=c(75,260,820,1650,2300,4000,5300)  
#variable réponse
```



```
tableau=data.frame(rangAnnee, montantAchat)
```

```
#Q1b
```

```
x11()
```

```
dev.off()
```

```
plot(tableau, main="Nuage de points du montant d'achats  
en fonction de l'année")
```

```
#On observe une dépendance qui semble exponentielle (ne  
semble pas linéaire)
```

```
#Q1c
```

```
cor(tableau)#0.9664639 Proche de 1 il y a donc une  
dépendance (croissante) importante entre le montant d'achat  
et l'année
```

```
#Q1d
```

```
lmExo2=lm(montantAchat~rangAnnee,  
data=tableau);lmExo2
```

```
#achats(annee)=879.8annee-581.6
```

```
summary(lmExo2)
```

```
residuals((lmExo2))
```

```
#Q1e
```

```
abline(lmExo2, col='blue')
```

```
#Q1f
```

```
predict(lmExo2, data.frame(rangAnnee=7))
```

```
#y(7)=879.8*7-581.6=5577
```

```
#Cette prévision n'est peut-être pas fiable
```

```
#Q2a
```

```

racine_montantAchats=sqrt(montantAchat)
reg2_racine=lm(racine_montantAchats~rangAnnee);reg2_racine
plot(rangAnnee, racine_montantAchats, main="Nuage de points de la racine du montant d'achats en fonction de l'année")
abline(reg2_racine, col="blue")
plot(log(montantAchat)~rangAnnee)#La dépendance n'est pas exponentielle
summary(reg2_racine)
predict(reg2_racine, data.frame(rangAnnee=7))^2
annee2=rangAnnee^2

```

#Q2b

#10.928x+6.936

#Q3

lm(montantAchat~annee2+rangAnnee+1)#Regression linéaire multiple

$130 \cdot 7^2 + 100 \cdot 7 + 68$

#premier modèle : achat = a+annee+b

#deuxieme modèle: achat = (a*annee+b)

$\wedge^2 = a'annee^2 + 2ab \cdot annee + b$

#troisieme modèle: achat = a*annee^2+b*annee+c

#Q4

#Les trois prévisions sont 5577, 6961, 7138, la dernière est la plus proche 7700

#Exo3

#Q1

```
diam=c(8.3,8.6,8.8,10.5,10.7,10.8,11.0,11.0,11.1,11.2,11.3,
11.4,11.4,11.7,12.0,12.9,12.9,13.3,13.7,13.8,14.0,14.2,14.5,
16.0,16.3,17.3,17.5,17.9,18.0,18.0,20.6)#variable
explicative
haut=c(70,65,63,72,81,83,66,75,80,75,79,76,76,69,75,74,85
,86,71,64,78,80,74,72,77,81,82,80,80,80,87)#variable
reponse
dataExo3=data.frame(diam,haut);dataExo3
```

#Q2

```
plot(diam, haut, main="Nuage de points de la hauteur de
l'arbre en fonction de son diamètre")
#On observe qu'aucune corrélation ne semble exister
```

#Q3

```
reg3=lm(haut~diam, dataExo3)
summary(reg3)
cor(dataExo3)
#La modélisation linéaire n'est pas adaptée
```

#Q4

```
data_arbres_mod=rbind(dataExo3, data.frame(haut=114.75,
diam=50))
reg3_mod=lm(haut~diam,
data=data_arbres_mod);summary(reg3_mod)
cor(data_arbres_mod)
plot(haut~diam, data=data_arbres_mod)
#Les coefficients de corrélation et le R squared sont biens
meilleurs, mais la dépendance linéaire n'est toujours pas
pertinente
```

TD5 :

```
help(range)
```

```
help(ecdf)
```

```
#Q1
```

```
nb_enfants = c(1:8,10)
```

```
effectifs = c(510,248,132,55,29,15,2,8,1)
```

```
sum(effectifs)
```

```
data = rep(nb_enfants, effectifs);data
```

```
#Q2
```

```
x11()
```

```
dev.off()
```

```
barplot(effectifs, nb_enfants, main="Distribution du  
nombre d'enfants", xlab="Nombre d'enfants",  
ylab="Effectifs")
```

```
mode_max=nb_enfants[which.max(effectifs)];mode_max
```

```
mode_min=nb_enfants[which.min(effectifs)];mode_min
```

```
#Q3
```

```
freq=effectifs/sum(effectifs);freq
```

```
freq_cum=cumsum(freq);freq_cum
```

```
tableau_freq=data.frame(nb_enfants, effectifs, freq,  
freq_cum);tableau_freq
```

```
plot(nb_enfants, freq_cum, type="s", main="Fréquences  
cumulées", xlab="Nombre d'enfants", ylab="Fréquence  
cumulée")
```

```
#Q4
```

```
summary(effectifs)
```

```
boxplot(data,main="Boxplot du nombre d'enfants")
```

```
boxplot.stats(data)$stats
```

#Q5

```
moyenne=mean(data)
variance=sum((nb_enfants-moyenne)^2*effectifs) /
sum(effectifs)
ecart_type=sqrt(variance)
```

#Q6

```
plot(freq,col="red") #distribution empirique
1+rgeom(n=10,p=1/2)
dgeom(0:10,p=1/2) #P(X=n) pour n allant de 0 à 10
points(x=1:10,y=dgeom(0:9,p=1/(1+moyenne)),col="blue")
```

TD6 :

```
classe=read.table(file="Classe.data.txt", header=T)
```

#Q1

```
table(classe$difficulte)
```

#Q2

```
plot(ecdf(classe$difficulte)) #ecdf ne s'applique qu'à des
séries statistiques quantitatives
```

#Q3

```
boxplot(classe$difficulte)
```

#Q4

```
classe$serie=="S" # TRUE OU FALSE Selon que l'indice
donne S ou ES
classe$difficulte[classe$serie=="S"] #Donne le vecteur des
difficultés pour la série S
```

```
classe$difficulte[classe$serie=="ES"] #Donne le vecteur  
des difficultés pour la série ES  
par(mfrow=c(1,2))  
boxplot(classe$difficulte[classe$serie=="S"],main="S")  
boxplot(classe$difficulte[classe$serie=="ES"],main="ES")
```

TD7 :

#Exercice1

#Q1 Voir feuille

```
loup=read.table("loups.csv", header=T)  
attach(loup)
```

#Q2

```
x11()
```

```
dev.off()
```

```
par(mfrow=c(1,2))
```

```
plot(age, empreinte, main="Nuages de points de l'empreinte  
en fonction de l'age")
```

```
plot(age, ecartement, main="Nuages de points de  
l'ecartement en fonction de l'age")
```

```
dev.copy2pdf(file="nuages_Lemaitre")
```

#Q3

```
cor(loup)
```

#Q4 Voir feuille

#Q5

```
reg_lineaire=lm(ecartement~age, data=loup);reg_lineaire
```

```
abline(reg_lineaire, col="blue")
```

```
dev.copy2pdf(file="droite_Lemaitre")
```

#Q6

```
summary(reg_lineaire)  
residuals(reg_lineaire)
```

#Q7

```
loup_mod=rbind(loup, data.frame(age,  
empreinte=17 ,ecartement=105))
```

#Exo2

#Q1 Voir feuille

```
bacteries=read.table("bacteries.csv", header=T)  
attach(bacteries)  
plot(temps, taille, main="Nuage de points de la taille des  
bactéries en fonction du temps de culture")
```

#Q2

```
taille_mod=log(taille)  
plot(temps, taille_mod, main="Nuage de points de ln(taille  
des bactéries) en fonction du temps de culture")
```

#Q3

```
reg_lineaire_bacterie=lm(temps~taille_mod,  
data=bacteries);reg_lineaire_bacterie  
summary(reg_lineaire_bacterie)  
residuals(reg_lineaire_bacterie)
```

#Q4

```
predict(reg_lineaire_bacterie, data.frame(taille_mod=12))
```

CC1 :

#Exo1

#Q1

```
individu=seq(1,34, by=1)
```

```
genre=c("H","H","F","F","F","H","F","F","F","H","H","F",  
"H","F","F","H","H","H","H","F","F","F","F","F","H","F",  
"F","H","F","F","F","H","F","F")
```

```
vehicule=c("V","V","NV","NV","NV","NV","NV","NV","  
NV","V","NV","V","NV","NV","NV","NV","NV","NV","  
V","NV","V","NV","V","NV",  
"V","NV","NV","V","NV","NV","NV","V","NV","V")
```

#Q2

```
etude=data.frame(Genre=genre, Vehicule=vehicule)
```

#Q3

```
table_etude=table(etude)
```

#Q4

```
x11()
```

```
barplot(table_etude,
```

```
legend=rownames(table_etude),beside=T,col=c("red","blue  
"))
```

```
plot(table_etude) #ou mosaicplot
```

#les effectifs chez les femmes semblent déséquilibrés. On fait un test du chi-deux

#Q5

```
chisq.test(table_etude)
```

#p-valeur de 8% : faible présomption contre l'hypothèse

null

#Exo2

#Q1

```
load(file="banque.rda")
```

```
attach(banque)
```

```
etude1_exo2=data.frame(csp, cableue)
```

```
tc1_exo2=table(etude1_exo2)
```

```
etude2_exo2=data.frame(csp, porttit)
```

```
tc2_exo2=table(etude2_exo2)
```

```
etude3_exo2=data.frame(age, eparlog)
```

```
tc3_exo2=table(etude3_exo2)
```

```
etude4_exo2=data.frame(sexe, assurvi)
```

```
tc4_exo2=table(etude4_exo2)
```

#Q2

```
x11()
```

```
dev.off()
```

```
par(mfrow=c(2,4))
```

```
barplot(tc1_exo2,
```

```
legend=rownames(tc1_exo2),beside=T,col=rainbow(length(  
tc1_exo2)))
```

```
mosaicplot(tc1_exo2,col=rainbow(length(tc1_exo2)))
```

```
barplot(tc2_exo2,
```

```
legend=rownames(tc2_exo2),beside=T,col=rainbow(length(  
tc2_exo2)))
```

```
mosaicplot(tc2_exo2,col=rainbow(length(tc2_exo2)))
```

```
barplot(tc3_exo2,  
legend=rownames(tc3_exo2),beside=T,col=rainbow(length(  
tc3_exo2)))  
mosaicplot(tc3_exo2,col=rainbow(length(tc3_exo2)))
```

```
barplot(tc4_exo2,  
legend=rownames(tc4_exo2),beside=T,col=rainbow(length(  
tc4_exo2)))  
mosaicplot(tc4_exo2,col=rainbow(length(tc4_exo2)))
```

#Q3

```
chisq.test(tc1_exo2)#très forte présomption  
chisq.test(tc2_exo2)#très forte présomption  
chisq.test(tc3_exo2)#forte présomption  
chisq.test(tc4_exo2)#très forte présomption
```

